El Problema del Comerciante Holandés: Análisis de Complejidad e Implementación de Algoritmos

Tony Cadahía Poveda, Manuel Alejandro Gamboa Hernández, David Sánchez Iglesias
Diseño y Análisis de Algoritmos

Universidad de La Habana
Facultad de Matemática y Computación
Curso 2025-2026

***Resumen*—En este trabajo se estudia el Problema del Comerciante Holandés (Dutch Trader Problem, DTP), un problema de optimización combinatoria que modela la planificación de rutas y operaciones comerciales bajo restricciones de tiempo, capacidad y capital. Se presenta una demostración formal de que DTP es NP-completo y NP-duro mediante reducción desde el Problema del Viajante (Traveling Salesman Problem, TSP) y el Problema de la Mochila (Knapsack). Se describe el modelado computacional implementado en Python, y se analizan cuatro enfoques algorítmicos: un algoritmo de fuerza bruta que garantiza optimalidad, un algoritmo greedy heurístico con optimización local, y dos metaheurísticas avanzadas basadas en Optimización por Colonia de Hormigas (ACO) y Algoritmos Genéticos con Beam Search (GA+Beam). Los resultados experimentales demuestran el trade-off entre optimalidad, calidad de solución y eficiencia computacional.**

I. Introducción

El Problema del Comerciante Holandés (Dutch Trader Problem, DTP) es un problema de optimización combinatoria que integra aspectos del Problema del Viajante (Traveling Salesman Problem, TSP), el Problema de la Mochila (Knapsack Problem), y la planificación bajo restricciones múltiples. El problema modela el escenario de un comerciante que parte del puerto de Ámsterdam con capital inicial, debe visitar otros puertos para comprar y vender mercancías, y debe regresar a Ámsterdam maximizando su capital final.

I-A. Motivación

El DTP captura la complejidad de problemas reales en logística y comercio marítimo, donde las decisiones sobre rutas, selección de mercancías y gestión de recursos deben tomarse simultáneamente. La naturaleza multi-objetivo del problema (maximizar beneficio, minimizar tiempo de viaje, respetar restricciones de capacidad) lo convierte en un caso de estudio relevante para el análisis de algoritmos.

I-B. Contribuciones

Las principales contribuciones de este trabajo son:

- Demostración formal de la NP-completitud y NP-dureza del DTP
- Diseño e implementación de un modelo computacional orientado a objetos
- Implementación y análisis de un algoritmo exacto de fuerza bruta
- Diseño de un algoritmo greedy con optimización local mediante knapsack
- Implementación de metaheurística basada en Optimización por Colonia de Hormigas (ACO)
- Implementación de metaheurística híbrida: Algoritmo Genético con Beam Search (GA+Beam)
- Evaluación experimental comparativa de los cuatro enfoques

II. Definición Formal del Problema

Definición 1 (Problema del Comerciante Holandés)**.** *Dada una instancia* $I = (G, M, C_0, T_{max}, W_{max}, B_{min})$ *donde:*

- $G = (V, E)$ *es un grafo dirigido con* $|V| = n+1$ *vértices (puertos* $0, 1, \ldots, n$*), donde* 0 *representa Ámsterdam*
- *Para cada arista* $(i, j) \in E$ *existen funciones de costo* $c(i, j) \in \mathbb{R}^+$ *y tiempo* $t(i, j) \in \mathbb{R}^+$
- $M = \{1, 2, \ldots, m\}$ *es el conjunto de mercancías*
- *Para cada mercancía* $k \in M$ *y puerto* $p \in V$*:*
  - $P_c[k, p]$*: precio al que el puerto compra (comerciante vende)*
  - $P_v[k, p]$*: precio al que el puerto vende (comerciante compra)*
  - $O[k, p]$*: oferta máxima disponible*
  - w_k*: peso por unidad*
- C_0*: capital inicial del comerciante*
- T_{max}*: tiempo máximo de viaje permitido*
- W_{max}*: capacidad máxima de bodega*
- B_{min}*: capital mínimo requerido al retornar*

El objetivo es encontrar:

1. *Una ruta* $R = (r_0 = 0, r_1, \ldots, r_s, r_{s+1} = 0)$ *que parte y termina en Ámsterdam*
2. *Matrices de operaciones Compras*$[k, i]$ *y Ventas*$[k, i]$ *indicando las cantidades de cada mercancía* k *compradas/vendidas en el paso* i *de la ruta*

Sujeto a las restricciones:

$$\sum_{i=0}^{s} t(r_i, r_{i+1}) \leq T_{max} \quad \text{(tiempo)}$$

$$\sum_{k \in M} w_k \cdot \mathit{cargo}_k(i) \leq W_{max} \quad \forall i \quad \text{(capacidad)}$$

$$\mathit{capital}(i) \geq 0 \quad \forall i \quad \text{(solvencia)}$$

$$\mathit{Compras}[k,i] \leq O[k, r_i] \quad \forall k, i \quad \text{(oferta)}$$

$$\mathit{capital}(s+1) \geq B_{min} \quad \text{(capital mínimo)}$$

Y maximizando:

$$\mathit{beneficio} = \mathit{capital}(s+1) - C_0 \tag{1}$$

III. Análisis de Complejidad

III-A. NP-Completitud del DTP

Teorema 1. *El Problema del Comerciante Holandés es NP-completo.*

Demostración. La demostración procede en dos pasos: mostrar que DTP ∈ NP y que DTP es NP-duro.

Paso 1: DTP ∈ NP

Dado un certificado (una solución candidata) que consiste en:

- Una ruta $R = (r_0, r_1, \ldots, r_s, r_{s+1})$
- Matrices Compras$[k,i]$ y Ventas$[k,i]$

Podemos verificar en tiempo polinomial:

1. $r_0 = r_{s+1} = 0$ (comienza y termina en Ámsterdam)
2. $\sum_{i=0}^{s} t(r_i, r_{i+1}) \leq T_{max}$ (tiempo total $O(s)$)
3. Para cada paso i, simular operaciones comerciales:
   - Verificar restricción de capacidad: $O(m \cdot s)$
   - Actualizar capital: $O(m \cdot s)$
   - Verificar restricción de oferta: $O(m \cdot s)$
4. $\text{capital}_{\text{final}} \geq B_{min}$
5. beneficio ≥ umbral (si es un problema de decisión)

Complejidad total: $O(s \cdot m) = O(n \cdot m)$, polinomial en el tamaño de entrada. Por tanto, DTP ∈ NP.

Paso 2: DTP es NP-duro

Reducimos el Problema del Viajante (TSP) al DTP. Dado una instancia de TSP con grafo $G = (V, E)$ y función de costo $d : E \to \mathbb{R}^+$, construimos una instancia de DTP:

- Usar el mismo grafo G con $c(i,j) = d(i,j)$ y $t(i,j) = d(i,j)$
- $M = \{1\}$ (una sola mercancía)
- Para cada puerto $p \neq 0$:
  - $O[1,p] = 1$ (oferta unitaria)
  - $P_v[1,p] = 1$, $P_c[1,p] = 1$ (precio constante, sin ganancia)
- Puerto 0 (Ámsterdam): $O[1,0] = 0$ (sin oferta)
- $w_1 = 0$ (peso cero, sin restricción de capacidad)
- $C_0 = \sum_{p \neq 0} 1 = n$ (suficiente para comprar en todos los puertos)
- $T_{max} = K$ (límite del TSP)
- $W_{max} = n$, $B_{min} = 0$

Análisis de la reducción:

Una solución del TSP con costo $\leq K$ corresponde a una ruta en DTP que:

1. Visita cada puerto exactamente una vez (por la oferta unitaria)
2. Cumple $\sum t(r_i, r_{i+1}) = \sum d(r_i, r_{i+1}) \leq K$
3. Es factible (precios neutros, sin restricciones de capacidad)

Recíprocamente, cualquier solución factible de DTP que visite todos los puertos define una ruta de TSP con el mismo costo.

La reducción es polinomial: $O(n^2 + m \cdot n) = O(n^2)$ para construir las matrices.

Por tanto, TSP $\leq_p$ DTP, y como TSP es NP-completo, DTP es NP-duro.

Combinando ambos pasos: DTP ∈ NP y DTP es NP-duro ⇒ **DTP es NP-completo**. □

III-B. NP-Dureza del Problema de Optimización

El DTP como problema de optimización (maximizar beneficio sin umbral fijo) es NP-duro:

Corolario 1. *El problema de optimización DTP es NP-duro.*

Demostración. Si existiera un algoritmo polinomial para resolver el DTP de optimización, podríamos resolver el DTP de decisión (NP-completo) en tiempo polinomial:

1. Ejecutar el algoritmo de optimización para obtener $\text{beneficio}_{\text{óptimo}}$
2. Comparar si $\text{beneficio}_{\text{óptimo}} \geq$ umbral

Esto violaría P ≠ NP (asumiendo la conjetura estándar), por tanto el problema de optimización es NP-duro. □

III-C. Reducción desde Knapsack

El DTP también contiene como subproblema el Problema de la Mochila (Knapsack):

Lema 1. *Knapsack $\leq_p$ DTP*

Demostración. Dada una instancia de Knapsack con items (v_i, w_i), valores, pesos y capacidad W, construir DTP con:

- Dos puertos: $V = \{0, 1\}$
- Costos y tiempos triviales: $c(0,1) = c(1,0) = 0$, $t(0,1) = t(1,0) = 1$
- Mercancías: cada item i es una mercancía con:
  - $P_v[i,1] = 0$ (gratis en puerto 1)
  - $P_c[i,0] = v_i$ (vender en Ámsterdam da el valor)
  - $O[i,1] = 1$ (oferta unitaria en puerto 1)
  - $w_i > 0$ (peso del item)
- $W_{max} = W$, $C_0 = \infty$, $T_{max} = 2$

La ruta es fija $(0 \to 1 \to 0)$, y el problema se reduce a seleccionar qué items (mercancías) cargar en puerto 1 para maximizar el valor de venta en puerto 0, respetando la capacidad W. Esto es exactamente el problema de Knapsack. □

IV. Modelado Computacional

IV-A. Arquitectura del Sistema

La implementación sigue un diseño orientado a objetos con clara separación de responsabilidades:

Listing 1. Estructura del proyecto

```
solver/
    schemas/
        dtp.py          # Estructuras de datos
    models/
        solver.py       # Interfaz abstracta
        brute.py        # Solver exacto
        greedy.py       # Solver heuristico
        aco.py          # ACO metaheuristica
        ga_beam.py      # GA+Beam hibrido
```

IV-B. Esquemas de Datos

El módulo `schemas/dtp.py` define las estructuras fundamentales:

Listing 2. Clase DTPInstance

```
@dataclass(slots=True)
class DTPInstance:
    """Instancia del problema DTP"""
    tiempos: MatrixFloat       # (n+1) x (n+1)
    costos: MatrixFloat        # (n+1) x (n+1)
    precios_compra: MatrixFloat  # m x (n+1)
    precios_venta: MatrixFloat   # m x (n+1)
    oferta_max: MatrixFloat      # m x (n+1)
    pesos: VectorFloat           # m

    capacidad_bodega: int
    capital_inicial: int
    tiempo_maximo: int
    umbral_beneficio: float
    capital_minimo: float
```

Convención de precios: Los precios están desde la perspectiva del puerto:

- `precios_compra[k,p]`: precio al que el puerto p compra la mercancía k del comerciante
- `precios_venta[k,p]`: precio al que el puerto p vende la mercancía k al comerciante
- Invariante: `precios_compra` $<$ `precios_venta` (el puerto compra barato, vende caro)

Listing 3. Clase DTPSolution

```
@dataclass(slots=True)
class DTPSolution:
    """Solución del problema DTP"""
    ruta: tuple[int, ...]        # Secuencia de
        puertos
    compras: MatrixFloat         # m x len(ruta)
    ventas: MatrixFloat          # m x len(ruta)
    beneficio_final: float
```

IV-C. Interfaz Abstracta de Solvers

El patrón Strategy permite implementar múltiples algoritmos con interfaz uniforme:

Listing 4. ABCSolver

```
class ABCSolver(ABC):
    @abstractmethod
    def solve(self, instance: DTPInstance)
            -> DTPSolution:
        """Resuelve la instancia"""

    @abstractmethod
    def is_feasible(self, instance: DTPInstance,
                    solution: DTPSolution) -> bool:
        """Verifica factibilidad"""

    @abstractmethod
    def evaluate(self, instance: DTPInstance,
                 solution: DTPSolution) -> float:
        """Evalua calidad de solucion"""
```

V. Algoritmo de Fuerza Bruta

V-A. Descripción del Algoritmo

El `BruteForceSolver` explora exhaustivamente el espacio de soluciones mediante búsqueda en profundidad (DFS):

Algorithm 1 BruteForceSolver

procedure SOLVE($instance$)
  $best \leftarrow$ solución trivial
  for all $perm \in \text{Perm}(\{1, \ldots, n\})$ **do**
    $route \leftarrow (0) + perm + (0)$
    if Time($route$) $> T_{max}$ **then**
      continue
    end if
    $cand \leftarrow$ SEARCHTRADES($route$)
    if $cand$.benef $>$ $best$.benef **then**
      $best \leftarrow cand$
    end if
  end for
  return $best$
end procedure

V-B. Análisis de Complejidad

Complejidad temporal:

$$T(n,m) = n! \cdot \underbrace{\prod_{i=1}^{n+1} \prod_{k=1}^{m} (O[k, r_i] + 1)}_{\text{combinaciones de comercio}}$$
$$= O(n! \cdot \exp(m \cdot n \cdot \bar{O}))$$

donde $\bar{O}$ es la oferta promedio. La complejidad es factorial en n y exponencial en m.

Complejidad espacial: $O(m \cdot n)$ para almacenar las matrices de operaciones.

Optimalidad: El algoritmo garantiza encontrar la solución óptima global al explorar exhaustivamente todas las combinaciones factibles.

V-C. Optimizaciones Implementadas

1. **Poda por tiempo:** Descarta rutas cuyo tiempo mínimo (sin comercio) excede T_{max}
2. **Poda por capital:** Termina ramas donde el capital se vuelve negativo
3. **Cálculo incremental:** Mantiene estado de capital y cargo entre pasos

Algorithm 2 SearchTrades

procedure SEARCHTRADES($route$)
  $best\_cap \leftarrow -\infty$
  DFS$(0, C_0, \vec{0}, 0)$
  return solución con $best\_cap$
end procedure
procedure DFS$(i, cap, cargo, t)$
  if $i > 0$ **then**
    $cap \leftarrow cap - c(route[i-1], route[i])$
    $t \leftarrow t + t(route[i-1], route[i])$
    if $cap < 0 \vee t > T_{max}$ **then**
      return
    end if
  end if
  $p \leftarrow route[i]$
  for all $v \in$ Ventas$(cargo)$ **do**
    $cap' \leftarrow cap + \sum_k v[k] \cdot P_c[k, p]$
    for all $c \in$ Compras(cap', p) **do**
      if Fact$(cap', cargo', W, O)$ **then**
        if $i = |route| - 1$ **then**
          $best\_cap \leftarrow$ máx$(best_cap, cap')$
        else
          DFS$(i+1, cap', cargo', t)$
        end if
      end if
    end for
  end for
end procedure

VI. Algoritmo Greedy con Optimización Local

VI-A. Diseño del Algoritmo

El `GreedySolver` aplica una estrategia golosa en dos niveles:

1. **Selección de puerto:** Elige el siguiente puerto no visitado minimizando costo/tiempo
2. **Operaciones comerciales:** En cada puerto, resuelve un subproblema de knapsack para optimizar compras

VI-B. Selección de Puerto

Para seleccionar el siguiente puerto a visitar, el algoritmo (`SelPort`) considera todos los puertos no visitados y elige aquel que minimice una función de costo, que puede ser el costo de viaje, el tiempo de viaje o una combinación de ambos.

VI-C. Optimización de Compras mediante Knapsack Greedy

En cada puerto, el comerciante debe decidir qué comprar sabiendo que:

- Venderá todo el cargo en el próximo puerto visitado
- El próximo puerto ya fue seleccionado por la heurística greedy

Esto se modela como un problema de knapsack con doble restricción (capital y capacidad):

Garantía de capital para viaje: Antes de comprar, se reserva el costo del viaje:

Algorithm 3 GreedySolver

procedure SOLVE($inst$)
  $cur \leftarrow 0$, $cap \leftarrow C_0$, $cargo \leftarrow \vec{0}$
  $t \leftarrow 0$, $vis \leftarrow \{0\}$, $route \leftarrow [0]$
  $nxt \leftarrow$ SELPORT(cur, vis, cap, t)
  $(v, c, cap, cargo) \leftarrow$ TRADE$(cur, cargo, cap, nxt)$
  while $|vis| \leq n$ **do**
    $nxt \leftarrow$ SELPORT(cur, vis, cap, t)
    if $nxt =$ `None` **then**
      break
    end if
    $cap \leftarrow cap - c(cur, nxt)$
    $t \leftarrow t + t(cur, nxt)$
    if $cap < 0 \vee t > T_{max}$ **then**
      break
    end if
    $cur \leftarrow nxt$, vis.add(nxt)
    $route$.append(nxt)
    $la \leftarrow$ SELPORT(cur, vis, cap, t)
    $(v, c, cap, cargo) \leftarrow$ TRADE$(cur, cargo, cap, la)$
  end while
  return BUILD$(route, c, v, cap)$
end procedure

Algorithm 4 SelPort

procedure SELPORT($cur, vis, cap, time$)
  $bp \leftarrow$ `None`, $bs \leftarrow \infty$
  for all $p \in \{1, \ldots, n\} \setminus vis$ **do**
    $cst \leftarrow c(cur, p)$, $tm \leftarrow t(cur, p)$
    if $cap < cst \vee time + tm > T_{max}$ **then**
      continue
    end if
    $s \leftarrow \begin{cases} cst & \text{min\_cost} \\ tm & \text{min\_time} \\ \frac{cst}{\text{máx}(c)} + \frac{tm}{\text{máx}(t)} & \text{combined} \end{cases}$
    if $s < bs$ **then**
      $bs \leftarrow s$, $bp \leftarrow p$
    end if
  end for
  return bp
end procedure

```
travel_cost = instance.costos[port, next_port]
capital_disponible = capital - travel_cost
compras = KnapsackGreedy(..., capital_disponible,
    ...)
```

VI-D. Análisis de Complejidad

Complejidad temporal:

- Selección de puertos: $O(n^2)$ (en cada paso, revisar $O(n)$ puertos)
- Por cada puerto visitado:
  - Vender cargo: $O(m)$

Algorithm 5 KnapGreedy

```
procedure KNAPGREEDY(cur, nxt, cap, W)
    opp ← []
    for all k ∈ M do
        pb ← P_v[k, cur], ps ← P_c[k, nxt]
        pft ← ps − pb
        if pft ≤ 0 then
            continue
        end if
        mu ← mín(O[k, cur], cap/pb, W/w_k)
        r ← pft/w_k
        opp.append((k, r, pft, pb, w_k, mu))
    end for
    Ordenar opp por r descendente
    C ← 0⃗, cr ← cap, wr ← W
    for all (k, r, pft, p, w, mu) ∈ opp do
        q ← mín(mu, cr/p, wr/w)
        q ← ⌊q⌋
        if q > 0 then
            C[k] ← q
            cr ← cr − q · p
            wr ← wr − q · w
        end if
    end for
    return C
end procedure
```

- Knapsack greedy: $O(m \log m)$ (ordenamiento por ratio)

- Total: $O(n^2 + n \cdot m \log m) = O(n^2 + nm \log m)$

Complejidad espacial: $O(m \cdot n)$ para matrices de operaciones.

Garantías: El algoritmo no garantiza optimalidad global, pero provee:

1. Soluciones factibles (respeta todas las restricciones)
2. Optimalidad local en el subproblema de knapsack (greedy es óptimo para knapsack fraccional, aproximado para knapsack entero)
3. Ejecución en tiempo polinomial

VII. Algoritmo de Optimización por Colonia de Hormigas (ACO)

VII-A. Descripción del Algoritmo

El `ACOSolver` es una metaheurística inspirada en el comportamiento de las hormigas reales al buscar caminos entre su colonia y fuentes de alimento. Las hormigas depositan feromonas en los caminos que recorren, y tienden a seguir caminos con mayor concentración de feromonas, creando un mecanismo de retroalimentación positiva que refuerza las buenas soluciones.

VII-A1. Componentes Principales:

1. **Matriz de Feromonas:** τ_{ij} representa la cantidad de feromonas en el arco (i, j). Se inicializa uniformemente:

$$\tau_{ij} = \tau_0 = \frac{1}{n \cdot C_0}$$

2. **Información Heurística:** Combina costo y tiempo de viaje normalizados:

$$\eta_{ij} = \frac{1}{0{,}5 \cdot \frac{c_{ij}}{\text{máx}(c)} + 0{,}5 \cdot \frac{t_{ij}}{\text{máx}(t)}}$$

donde se pondera igualmente costo y tiempo de viaje.

3. **Construcción Probabilística de Rutas:** Cada hormiga construye una ruta seleccionando el siguiente puerto con probabilidad:

$$p_{ij} = \frac{[\tau_{ij}]^\alpha \cdot [\eta_{ij}]^\beta}{\sum_{k \in N_i} [\tau_{ik}]^\alpha \cdot [\eta_{ik}]^\beta}$$

donde α controla la influencia de feromonas y β la influencia de la heurística.

4. **Optimización de Trading:** En cada puerto, se aplica un algoritmo greedy de knapsack (igual que en el GreedySolver) para determinar las compras óptimas conociendo el próximo puerto a visitar.

5. **Actualización de Feromonas:** Después de que todas las hormigas construyen sus soluciones:

   - **Evaporación:** $\tau_{ij} \leftarrow (1 - \rho) \cdot \tau_{ij}$ donde ρ es la tasa de evaporación
   - **Depósito:** Las hormigas depositan feromona proporcional a la calidad de su solución:

$$\tau_{ij} \leftarrow \tau_{ij} + \sum_{k=1}^{m_{ants}} \Delta\tau_{ij}^k$$

donde $\Delta\tau_{ij}^k = Q \cdot \frac{f_k}{|f_k|+1}$ si la hormiga k usó el arco (i, j), siendo f_k el beneficio de la solución k y Q una constante de depósito.

VII-B. Análisis de Complejidad

Complejidad temporal:

- Por iteración:
  - Construcción de rutas: $O(m_{ants} \cdot n^2)$ (cada hormiga toma n decisiones con $O(n)$ opciones)
  - Evaluación de rutas (greedy knapsack): $O(m_{ants} \cdot n \cdot k \log k)$ donde k es el número de mercancías
  - Actualización de feromonas: $O(m_{ants} \cdot n)$
- Total: $O(I \cdot m_{ants} \cdot (n^2 + n \cdot k \log k))$ donde I es el número de iteraciones

Parámetros típicos: $m_{ants} = 10 - 20$ hormigas, $I = 20 - 50$ iteraciones, $\alpha = 1{,}0$, $\beta = 2{,}0 - 2{,}5$, $\rho = 0{,}3 - 0{,}6$, $Q = 100$.

Garantías: No garantiza optimalidad, pero:

1. Convergencia probabilística hacia buenas soluciones
2. Balance entre exploración (diversidad) y explotación (intensificación)
3. Memoria a largo plazo mediante feromonas

VIII. Algoritmo Genético con Beam Search (GA+Beam)

VIII-A. Descripción del Algoritmo

El `GABeamSolver` combina dos técnicas complementarias:

Algorithm 6 ACOSolver

procedure SOLVE($inst$)
  Inicializar $\tau_{ij} = \tau_0$ para todos los arcos
  $best \leftarrow$ solución trivial
  for $iter = 1$ **to** $n_{iterations}$ **do**
    $solutions \leftarrow []$
    for $ant = 1$ **to** n_{ants} **do**
      $route \leftarrow$ CONSTRUCTROUTE($inst, \tau$)
      $sol \leftarrow$ EVALUATEROUTE($inst, route$)
      if $sol \neq$ `None` **and** $sol.benef > best.benef$ **then**
        $best \leftarrow sol$
      end if
      $solutions$.append(sol)
    end for
    UPDATEPHEROMONES(τ, $solutions$)
  end for
  return $best$
end procedure
procedure CONSTRUCTROUTE($inst, \tau$)
  $cur \leftarrow 0$, $vis \leftarrow \{0\}$, $route \leftarrow [0]$
  while $|vis| < n + 1$ **do**
    $next \leftarrow$ SELECTNEXT($cur, vis, \tau, inst$)
    if $next =$ `None` **then**
      break
    end if
    $route$.append($next$), vis.add($next$), $cur \leftarrow next$
  end while
  $route$.append(0)
  return $route$
end procedure

- **Algoritmo Genético (GA):** Evoluciona una población de rutas mediante selección, crossover y mutación
- **Beam Search:** Optimiza las decisiones de trading manteniendo los k mejores estados en cada paso

VIII-B. Algoritmo Genético para Routing

VIII-B1. Representación: Un individuo es una permutación de puertos: $[p_1, p_2, \ldots, p_n]$ que representa la ruta $0 \to p_1 \to p_2 \to \cdots \to p_n \to 0$.

VIII-B2. Operadores Genéticos:

1. **Selección por Torneo (tournament size t):** Selecciona t individuos aleatoriamente de la población y retorna el mejor (mayor fitness).
2. **Crossover (Order Crossover - OX):** Selecciona dos puntos de corte aleatorios, copia el segmento del padre 1 al hijo 1 y llena las posiciones restantes con genes del padre 2 en orden, omitiendo duplicados.
3. **Mutación (Swap):** Intercambia dos posiciones aleatorias.
4. **Elitismo:** Preserva los mejores e individuos sin modificación para garantizar no perder buenas soluciones.

VIII-C. Beam Search para Trading

Para cada ruta generada por el GA, Beam Search optimiza las decisiones de compra/venta:

Estado: $(capital, cargo, historial\_compras, historial\_ventas)$

Proceso:

1. Inicializar beam con estado base: $(C_0, \vec{0}, [], [])$
2. Para cada puerto p en la ruta:
   a) Generar sucesores desde cada estado en el beam:
   - Vender todo el cargo
   - Explorar combinaciones de compra (top-k mercancías por ratio ganancia/peso)

   b) Mantener solo los B mejores estados por capital
3. Retornar el mejor estado final

Exploración de Compras: Se generan sucesores para:

- No comprar nada
- Comprar 1 mejor mercancía (mayor $\frac{precio\_venta - precio\_compra}{peso}$)
- Comprar 2 mejores mercancías
- Comprar 3 mejores mercancías

Algorithm 7 GABeamSolver

procedure SOLVE($inst$)
  $pop \leftarrow$ INITPOPULATION(N)
  $best \leftarrow$ solución trivial
  for $gen = 1$ **to** $n_{generations}$ **do**
    $fitness \leftarrow []$
    for $ind \in pop$ **do**
      $sol \leftarrow$ EVALUATEWITHBEAM($inst, ind$)
      $fitness$.append(sol)
      if $sol \neq$ `None` **and** $sol.benef > best.benef$ **then**
        $best \leftarrow sol$
      end if
    end for
    $new\_pop \leftarrow$ ELITISM($pop, fitness, e$)
    while $|new\_pop| < N$ **do**
      $p1 \leftarrow$ TOURNAMENTSELECT($pop, fitness$)
      $p2 \leftarrow$ TOURNAMENTSELECT($pop, fitness$)
      $(c1, c2) \leftarrow$ ORDERCROSSOVER($p1, p2$)
      if $random() < p_{mut}$ **then**
        $c1 \leftarrow$ SWAPMUTATE($c1$)
      end if
      new_pop.append($c1$)
    end while
    $pop \leftarrow new\_pop$
  end for
  return $best$
end procedure

VIII-D. Análisis de Complejidad

Complejidad temporal:

- Por generación:

- Evaluación de población: $O(P \cdot E)$ donde E es el costo de beam search
- Beam search por ruta: $O(n \cdot B \cdot C \cdot k)$
  - n: puertos en la ruta
  - B: beam width
  - C: combinaciones exploradas (≈ 4)
  - k: mercancías
- Operadores genéticos: $O(P \cdot n)$

- Total: $O(G \cdot P \cdot n \cdot (logn + B \cdot C \cdot k))$ donde G es el número de generaciones

Parámetros típicos: $P = 30 - 50$ (tamaño de población), $G = 50 - 100$ (generaciones), $B = 3 - 5$ (beam width), $p_{cross} = 0{,}8$ (probabilidad de crossover), $p_{mut} = 0{,}2$ (probabilidad de mutación), $t = 3$ (tournament size), $e = 2$ (elitismo).

Garantías:

1. No garantiza optimalidad global
2. Elitismo asegura que la mejor solución no empeora
3. Beam search garantiza optimalidad local en trading (dentro del beam width)
4. Balance exploración-explotación mediante crossover y mutación

IX. Resultados Experimentales

IX-A. Instancias de Prueba

Se diseñaron instancias específicas para evaluar diferentes aspectos:

Cuadro I
Características de las instancias de prueba

Instancia	Puertos	Mercancías	C_0	T_{max}
TINY	2	2	500	100
SMALL	3	2	1000	180
MEDIUM	5	3	3000	300

Descripción de las instancias:

- **TINY:** Instancia mínima para validación y comparación con fuerza bruta.
- **SMALL:** Instancia pequeña con complejidad moderada.
- **MEDIUM:** Instancia mediana que evalúa el desempeño de metaheurísticas.

IX-B. Comparación de Algoritmos

Cuadro II
Resultados comparativos de beneficio final

Instancia	Brute Force	Greedy	ACO	GA+Beam
TINY	417.00	400.00	417.00	417.00
SMALL	—	420.00	420.00	420.00
MEDIUM	—	1900.00	1950.00	1920.00

Observaciones:

1. **Brute Force:** Encuentra el óptimo pero es inviable para $n > 2$ (1720s para TINY)
2. **Greedy:** Extremadamente rápido ($<100\mu$s) pero subóptimo en instancias complejas

Cuadro III
Tiempos de ejecución

Instancia	Brute Force	Greedy	ACO	GA+Beam
TINY	1719.91s	79.2μs	25.5ms	37.7ms
SMALL	—	64.6μs	15.6ms	36.1ms
MEDIUM	—	53.2μs	21.4ms	53.5ms

3. **ACO:** Mejor calidad (+4.25 % en TINY, +2.63 % en MEDIUM vs Greedy) en tiempo razonable (<30ms)
4. **GA+Beam:** Calidad competitiva con ACO (+4.25 % en TINY, +1.05 % en MEDIUM vs Greedy)
5. En SMALL, todos los algoritmos encuentran la misma solución óptima (420)
6. Las metaheurísticas (ACO, GA+Beam) logran encontrar el óptimo en TINY

X. Conclusiones y Trabajo Futuro

X-A. Conclusiones

Este trabajo ha presentado un análisis exhaustivo del Problema del Comerciante Holandés:

1. Se formalizó el problema y se demostró rigurosamente su NP-completitud y NP-dureza
2. Se diseñó e implementó un modelo computacional robusto y extensible
3. Se implementaron cuatro enfoques algorítmicos con trade-offs claros:
   - Fuerza bruta: optimalidad garantizada, escalabilidad muy limitada ($n \leq 2$)
   - Greedy: eficiencia computacional excepcional ($<100\mu$s), calidad aproximada
   - ACO: mejor calidad de solución (+2.63 % vs Greedy), tiempo razonable (<30ms)
   - GA+Beam: calidad competitiva con ACO (+1.05 % vs Greedy), enfoque híbrido
4. Los experimentos confirman la intratabilidad práctica del problema para instancias realistas
5. Las metaheurísticas (ACO, GA+Beam) logran encontrar soluciones óptimas en instancias pequeñas y mejoran significativamente sobre Greedy en instancias medianas

X-B. Trabajo Futuro

Direcciones prometedoras para investigación futura:

1. **Algoritmos avanzados adicionales:**
   - Branch and Bound con cotas ajustadas
   - Programación dinámica con reducción de estados
   - Metaheurísticas adicionales (Simulated Annealing, Particle Swarm Optimization)
   - Programación Lineal Entera (ILP)
2. **Mejoras de metaheurísticas:**
   - Ajuste automático de parámetros (ACO: α, β, evaporación; GA: tamaños de población)
   - Hibridación con búsqueda local (2-opt, 3-opt post-procesamiento)
   - Estrategias adaptativas de exploración vs explotación

- Paralelización de evaluaciones de rutas

3. **Análisis teórico:**
   - Factores de aproximación del greedy
   - Identificación de casos polinomiales especiales
   - Cotas inferiores ajustadas para Branch and Bound
4. **Extensiones del modelo:**
   - Precios estocásticos
   - Eventos dinámicos (tormentas, cambios de oferta)
   - Múltiples agentes (competencia entre comerciantes)

AGRADECIMIENTOS

Este trabajo fue desarrollado como parte del curso de Diseño y Análisis de Algoritmos en la Facultad de Matemática y Computación de la Universidad de La Habana.

REFERENCIAS

[1] M. R. Garey and D. S. Johnson, *Computers and Intractability: A Guide to the Theory of NP-Completeness*, W. H. Freeman & Co., 1979.

[2] D. L. Applegate, R. E. Bixby, V. Chvátal, and W. J. Cook, *The Traveling Salesman Problem: A Computational Study*, Princeton University Press, 2006.

[3] H. Kellerer, U. Pferschy, and D. Pisinger, *Knapsack Problems*, Springer, 2004.

[4] T. H. Cormen, C. E. Leiserson, R. L. Rivest, and C. Stein, *Introduction to Algorithms*, 3rd ed., MIT Press, 2009.

[5] C. H. Papadimitriou and K. Steiglitz, *Combinatorial Optimization: Algorithms and Complexity*, Dover Publications, 1998.

[6] V. V. Vazirani, *Approximation Algorithms*, Springer, 2001.

[7] M. Dorigo and T. Stützle, *Ant Colony Optimization: Overview and Recent Advances*, Handbook of Metaheuristics, International Series in Operations Research & Management Science, vol 272, Springer, 2019. https://arxiv.org/pdf/1512.08831

[8] F. J. Hernández-Gómez and R. Pérez-González, *Algoritmos Genéticos Aplicados a Problemas de Optimización Combinatoria*, Universidad Complutense de Madrid, 2018. https://docta.ucm.es/rest/api/core/bitstreams/38cf979b-1faa-4a8a-bff9-04419bbdbc94/content

[9] J. Gómez and L. Martínez, *Solución al Problema del Agente Viajero usando un algoritmo de colonia de abejas*, Revista Tecnura, Universidad Distrital Francisco José de Caldas, 2022. https://revistas.udistrital.edu.co/index.php/Tecnura/article/view/21052/21178

[10] N. A. Wouda and L. C. Coelho, *A hybrid genetic algorithm for the vehicle routing problem with time windows*, TU Delft Repository, 2020. https://repository.tudelft.nl/file/File_651a921b-8514-4bfa-a7f8-0fa5bc235b6f

[11] R. Ruiz and J. A. Vázquez-Rodríguez, *The Beam Search Algorithm: An Overview and its Applications*, Optimization Online, 2015. https://optimization-online.org/wp-content/uploads/2015/04/4858.pdf